# DL y DNN en Biología

Deep Learning en problemas bioinformáticos, Escalas de la biología
Pipeline de un problema de Deep Learning
ADN como input y Representación de secuencias (one-hot)
Construcción del dataset (TP / TN) Introducción a PyTorch

# ¿Qué problemas Bioinformáticos conocemos?

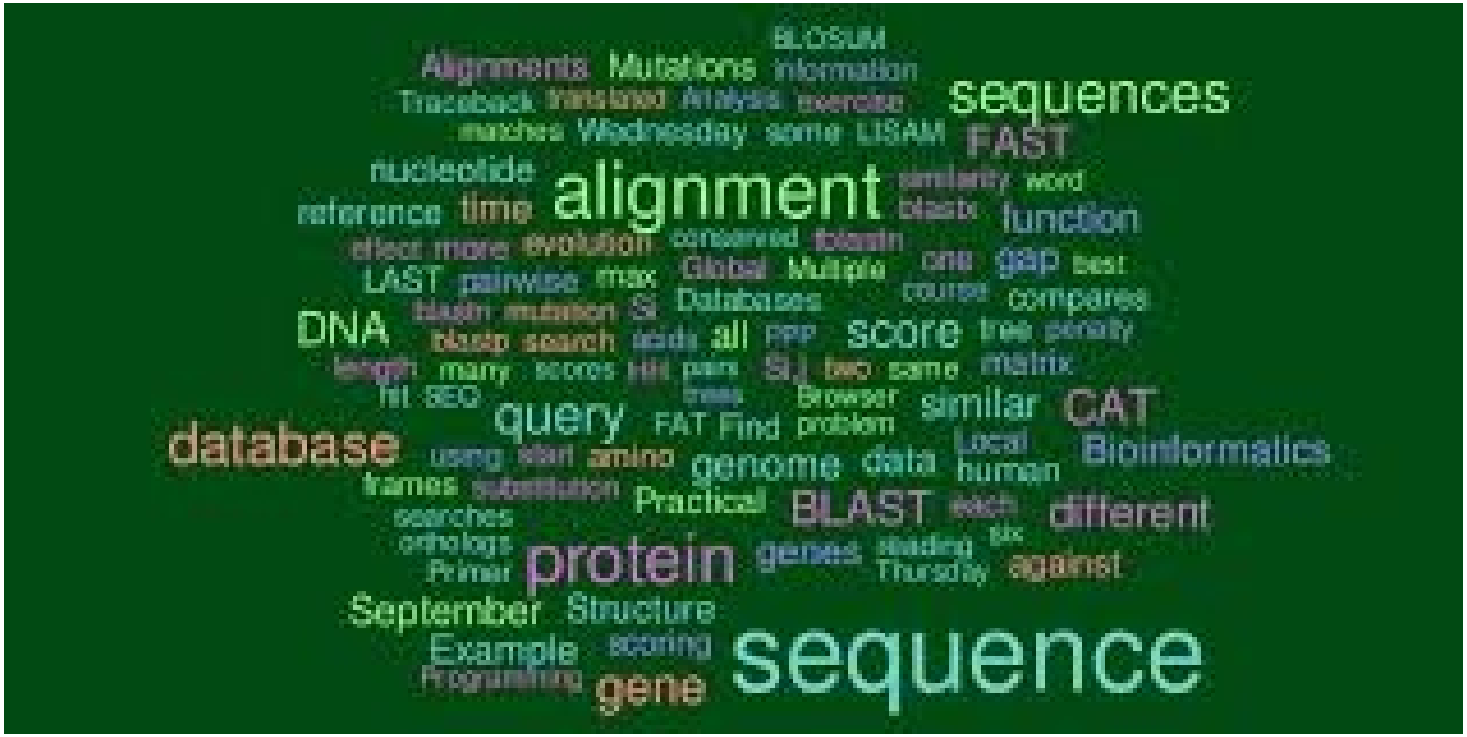

¿para qué problemas podemos usar DNN?

¿para cuáles vale la pena?

¿Cuáles son los “requisitos”?

# DL en Bioinformática

- ¿Qué problemas bioinformáticos conocemos?
  - Predicción de estructura,  función de proteínas, Detección de promotores / enhancers, Clasificación de variantes (patogénicas vs benignas),  Análisis de expresión génica (RNA-seq), Intergración de datos ómicos
- ¿Qué tipo de problemas son adecuados para DL?
  - Datos de alta dimensión, Relaciones no lineales complejas, Patrones difíciles de modelar explícitamente, Grandes volúmenes de datos, Señales distribuidas (no locales)
- ¿Cuándo vale la pena usar DL?
  - No sabemos diseñar features manuales,  El problema tiene estructura complejay Hay suficiente cantidad de datos
- ¿cuando Evitar DL cuando?
  - Dataset pequeño,  Problema simple o interpretable, Modelos clásicos funcionan bien (no reinventar la rueda)

- DL no es “la solución universal”, Es útil cuando la complejidad del problema lo justifica

# Las escalas de la biología: 1 Molecular

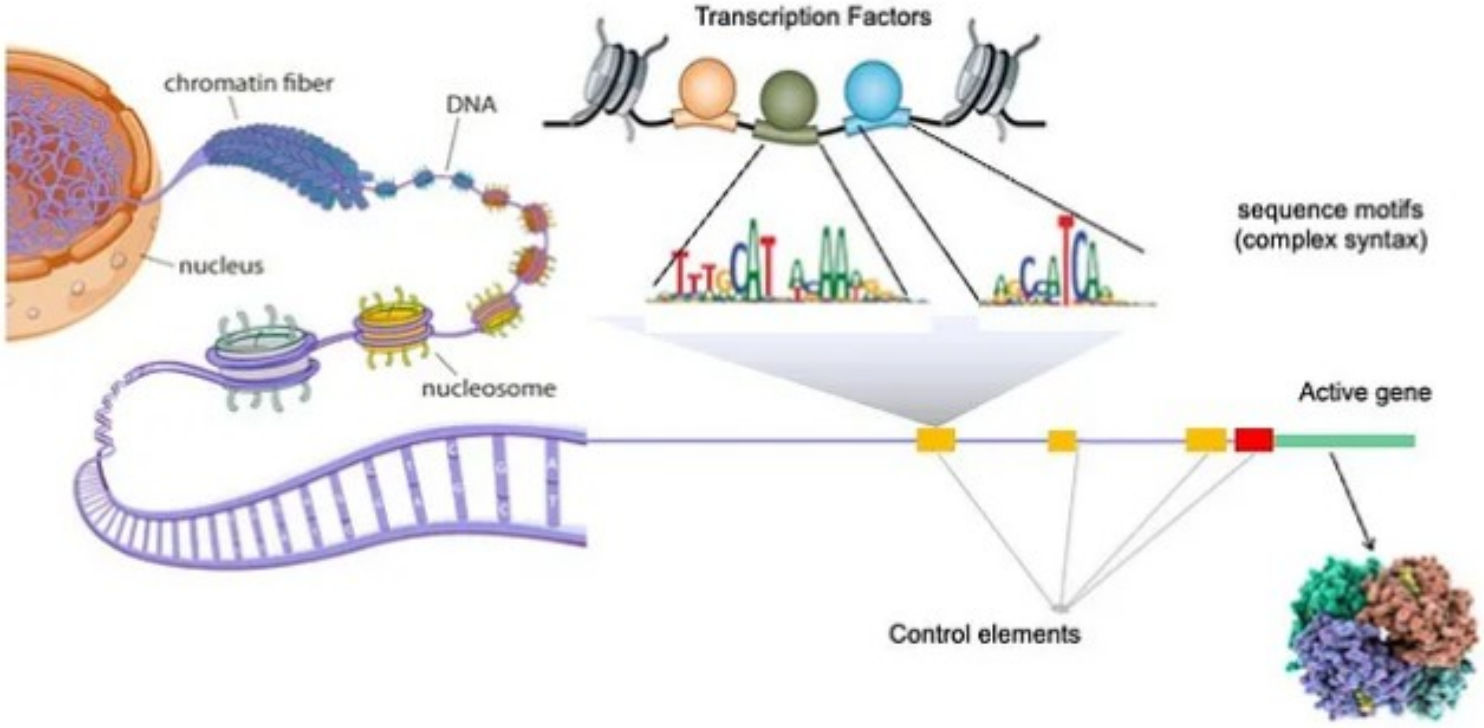

# Escala 2 Estructura

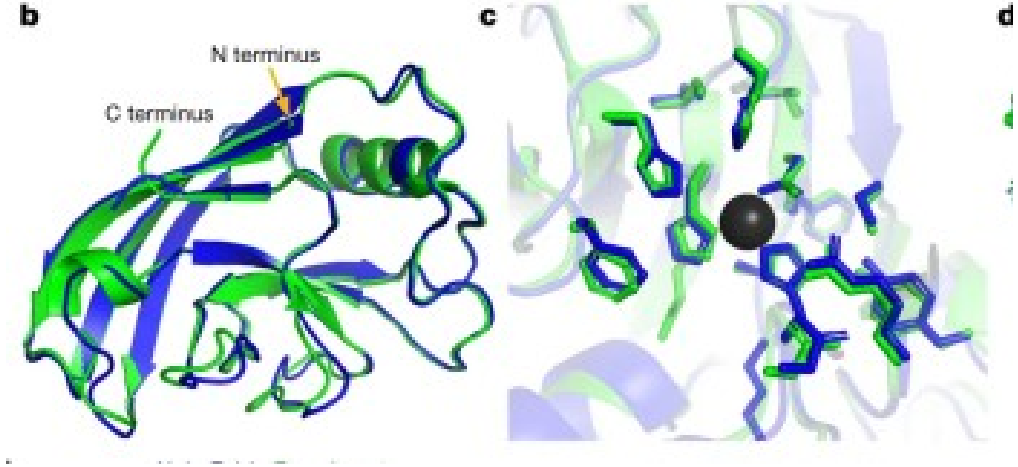


# Escala 3 Redes

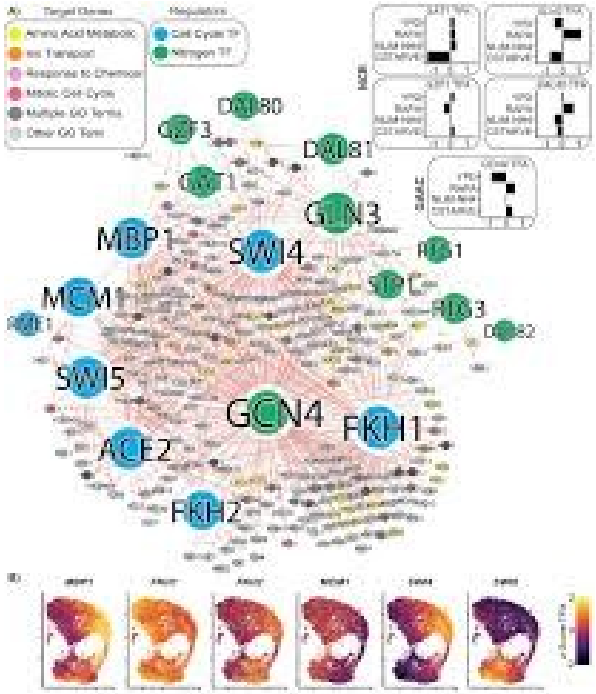

# Escala 4 Fenotipo

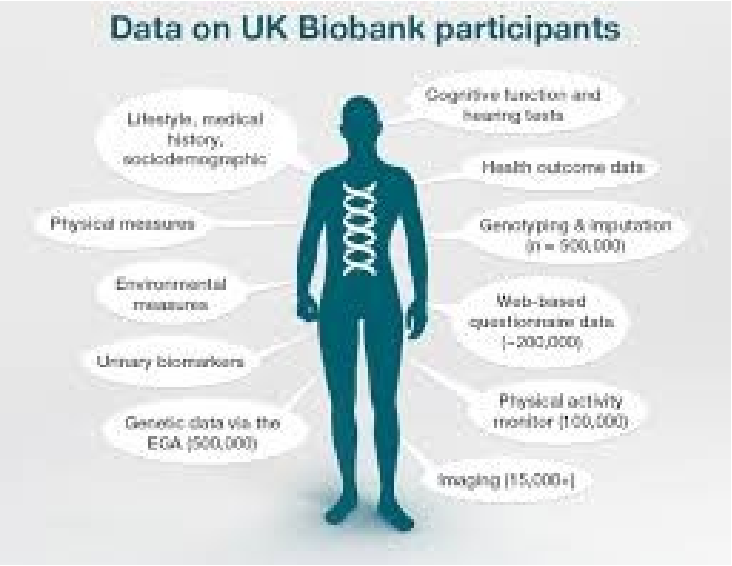

# Un poco de historia (1988)....

*J. Mol. Biol.* (1988) **202**, 865–884

## Predicting the Secondary Structure of Globular Proteins Using Neural Network Models

**Ning Qian and Terrence J. Sejnowski**

*Department of Biophysics*
*The Johns Hopkins University*
*Baltimore, MD 21218, U.S.A.*

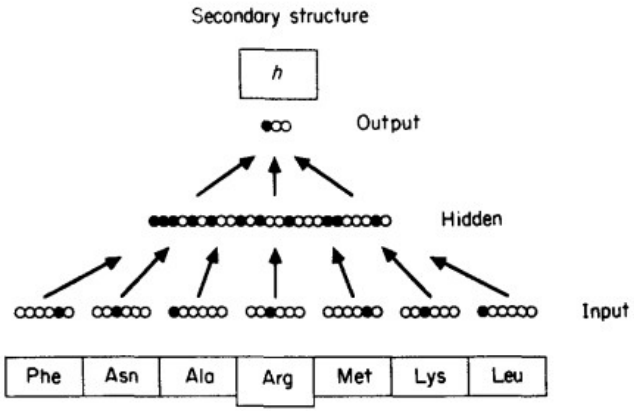


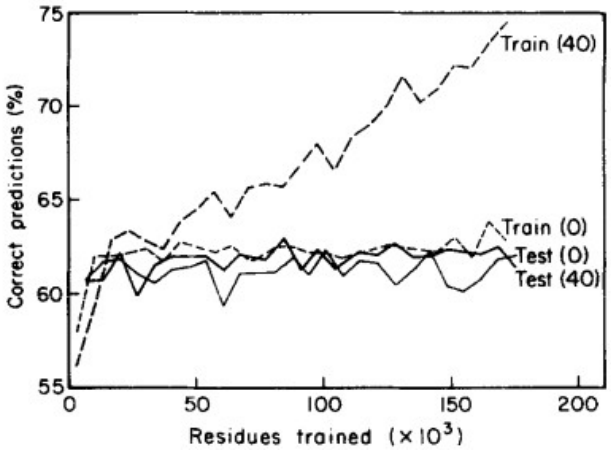

# Algunos “hitos”...

Neural Comput.  1996 Hybrid modeling, HMM/NN architectures, and protein applications P Baldi 1, Y Chauvin. DOI: 10.1162/neco.1996.8.7.1541

Nucleic Acids Res 1998 Using neural networks for prediction of the subcellular location of proteins A Reinhardt 1, T Hubbard DOI: 10.1093/nar/26.9.2230

Nat Med 2001 Classification and diagnostic prediction of cancers using gene expression profiling and artificial neural networks. J Khan et. al. DOI: 10.1038/89044

Bioinformatics 2002 Prediction of contact maps by GIOHMMs and recurrent neural networks using lateral propagation from all four cardinal corners G Pollastri 1, P Baldi DOI: 10.1093/bioinformatics/18.suppl_1.s62

Presente...

Article

# Accurate structure prediction of biomolecular interactions with AlphaFold 3

Nature | Vol 630 | 13 June 2024 | 493

nature machine intelligence

Article

https://doi.org/10.1038/s42256-024-00809-7

# Generative AI for designing and validating easily synthesizable and structurally novel antibiotics

Received: 10 March 2023

Accepted: 8 February 2024

Kyle Swanson[1,4], Gary Liu[2,4], Denise B. Catacutan[2], Autumn Arn
James Zou[1,3] & Jonathan M. Stokes[2]

Artic

Cell

# Predicting Splicing from Primary Sequence with Deep Learning

Science

Current Issue | First release papers | Archive | About | Submit n

IO. 6736 > SIMULATING 500 MILLION YEARS OF EVOLUTION WITH A LANGUAGE MODEL

OTEIN DESIGN

# 500 million years of evolution with a lan-el

ACCOUNTS of chemical research

pubs.acs.org/accounts

Article

# Advancing Ligand Docking through Deep Learning: Challenges and Prospects in Virtual Screening

Xujun Zhang, Chao Shen, Haotian Zhang, Yu Kang, Chang-Yu Hsieh,* and Tingjun Hou*

Cite This: Acc. Chem. Res. 2024, 57, 1500−1509

Read Online

# The Nobel Prize in Chemistry 2024

Chemists have long dreamed of fully understanding and mastering the chemical tools of life – proteins. This dream is now within reach. **Demis Hassabis** and **John Jumper** have successfully utilised artificial intelligence to predict the structure of almost all known proteins. **David Baker** has learned how to master life's building blocks and create entirely new proteins. The potential of their discoveries is enormous.

## They have revealed proteins' secrets through computing and artificial intelligence

# DL4Bio hands on

¿Cuál es el objetivo?

¿Qué datos necesito?

¿Qué datos tengo?

¿Que modelo-arquitectura uso?

¿Cómo lo entreno?

¿Cómo lo evalúo?

¿Como lo uso?

Idea clave:  El modelo es solo una parte
Datos + formulación del problema = impacto real

# La modern conceptual infogina comples al Deep Learning problem en bioinformática

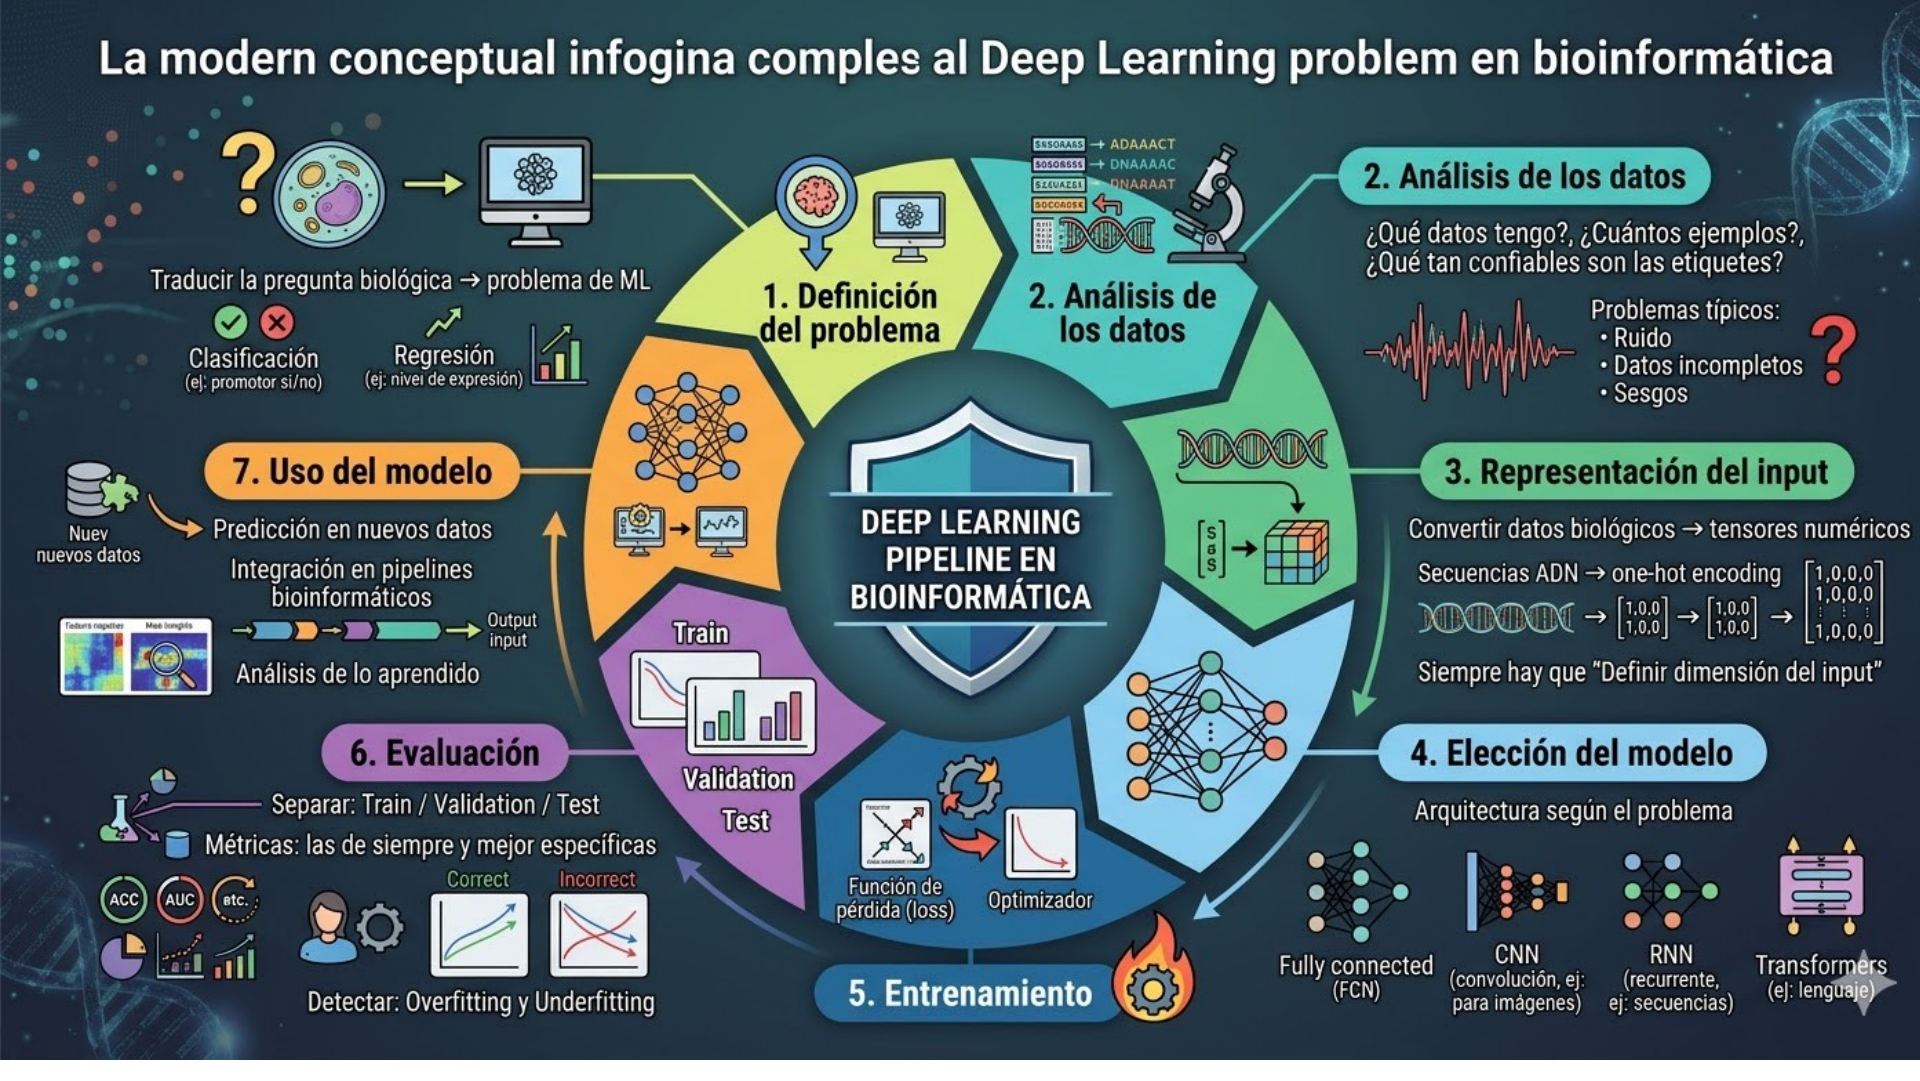

# Empecemos por el ADN

¿Qué información puede tener una secuenc
de ADN?

¿Qué datos hay disponibles sobre secuenc
de ADN?

¿Es un problema de Clasificación o
Regresión?

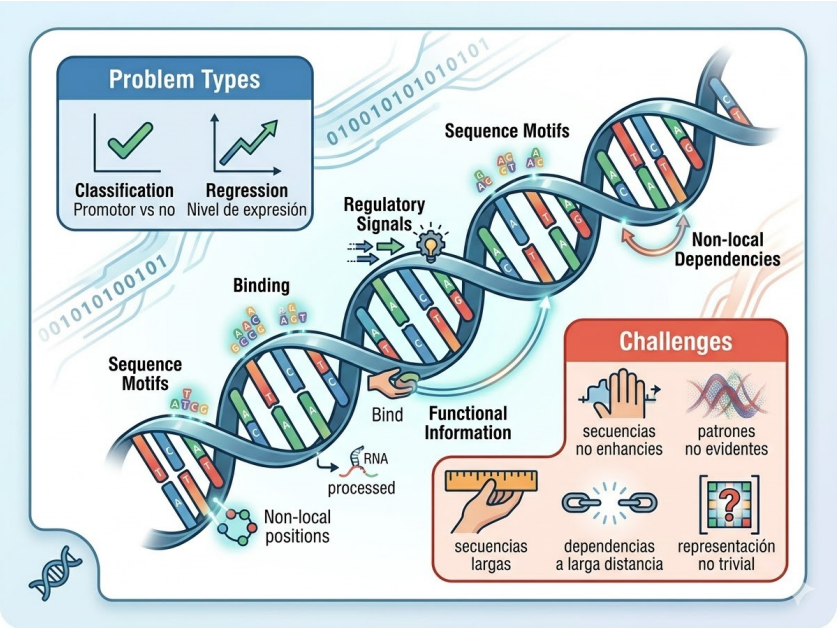


## El input:

ACTACGTGACTGATCACTGCATCACGCATCAGCACTTACTGGCAT

¿Cómo se lo doy a la red? ¿cuál es la dimensión del tensor de entrada?

# El One Hot Encoding

ACTACGTGACTGATCACTGCATCACGCATCAGCACTTACTGGCAT

[1000] [0100] [0001] [1000] [0100] [0010]

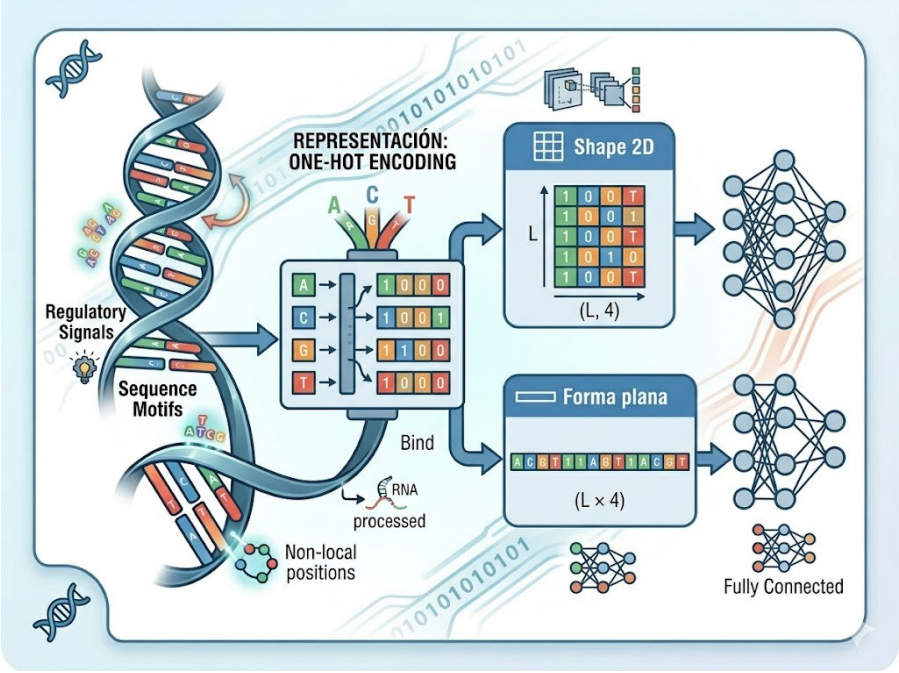


Y el output

¿cuál es la dimensión del tensor de salida?

# ¿Cómo lo entreno?

En teoría debo mostrarle secuencias que poseen (o no poseen) información biológica (Por ejemplo que son o no secuencias promotoras).

¿Cómo obtengo secuencias promotoras (Los True Positives)?

¿Cómo obtengo secuencias que NO son promotoras (Los True Negatives)?

Usualmente en biologìa “sólo” contamos con secuencias TP y debemos fabricar TN sintéticos (¿ideas?)

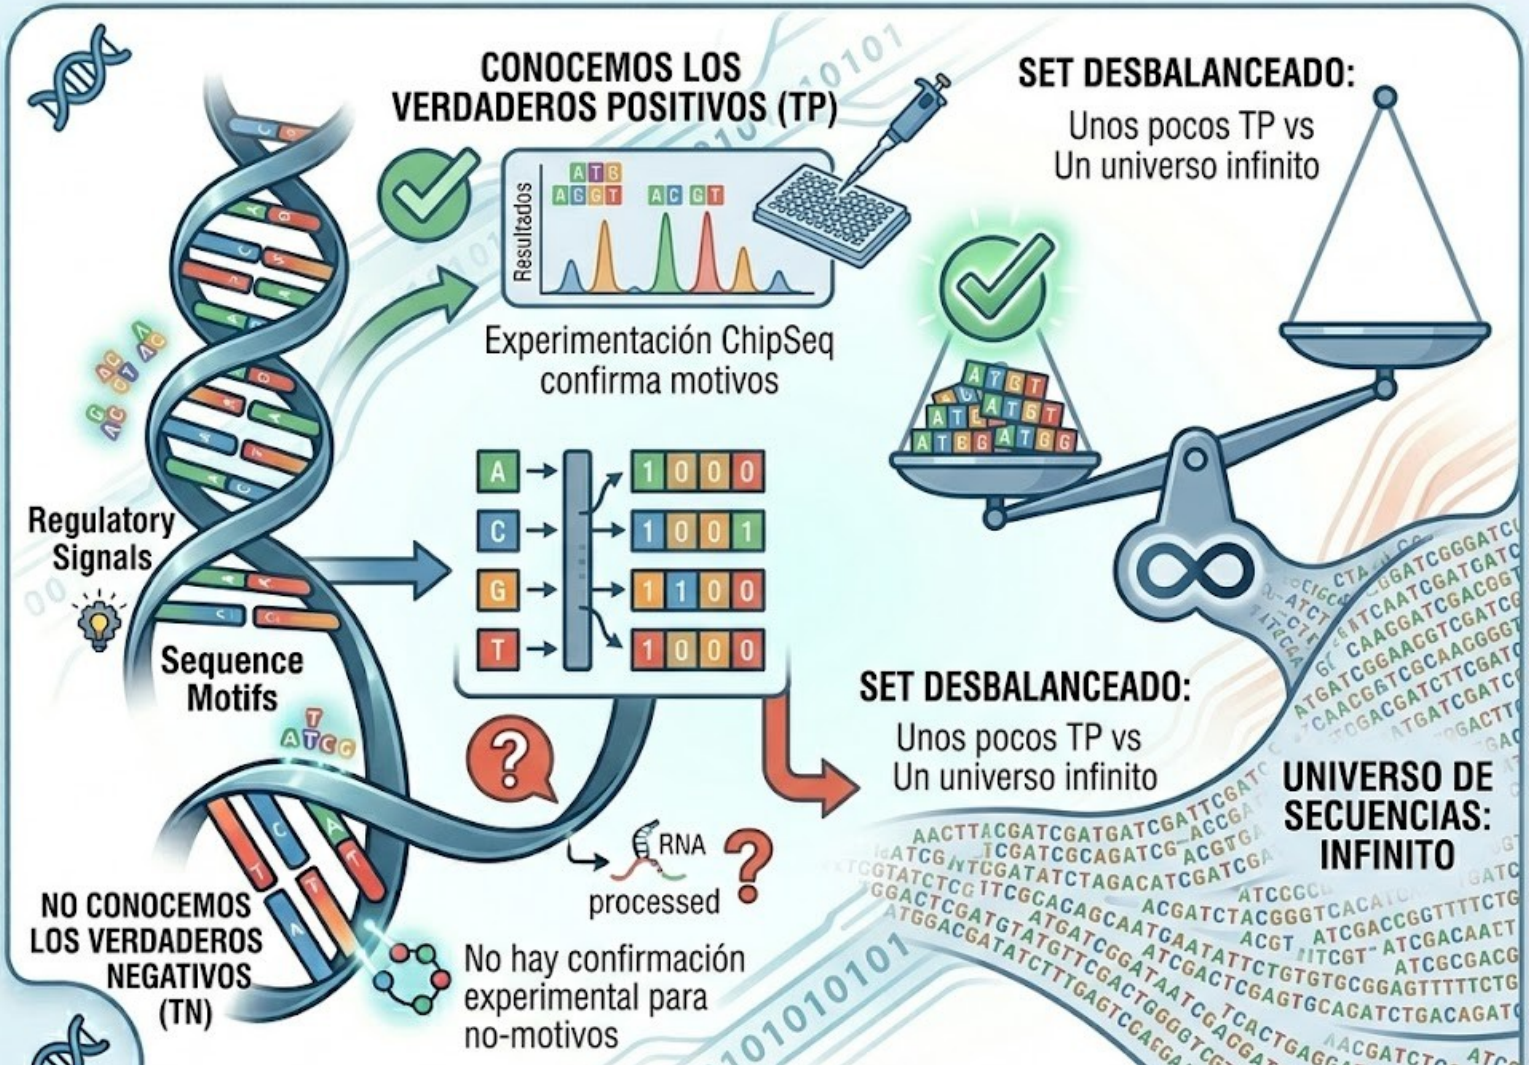
CONOCEMOS LOS VERDADEROS POSITIVOS (TP)
Resultados
Experimentación ChipSeq confirma motivos
SET DESBALANCEADO:
Unos pocos TP vs
Un universo infinito
Regulatory Signals
Sequence Motifs
A
C
G
T
1 0 0 0
1 0 0 1
1 1 0 0
1 0 0 0
SET DESBALANCEADO:
Unos pocos TP vs
Un universo infinito
UNIVERSO DE SECUENCIAS: INFINITO
RNA
processed
NO CONOCEMOS LOS VERDADEROS NEGATIVOS (TN)
No hay confirmación experimental para no-motivos

# Negativos Sintéticos

En muchos problemas biológicos No hay True Negatives reales
Solución práctica: Generar negativos sintéticos (TN artificiales) => Construir ejemplos que: No contengan la señal biológica y Sean comparables a los positivos

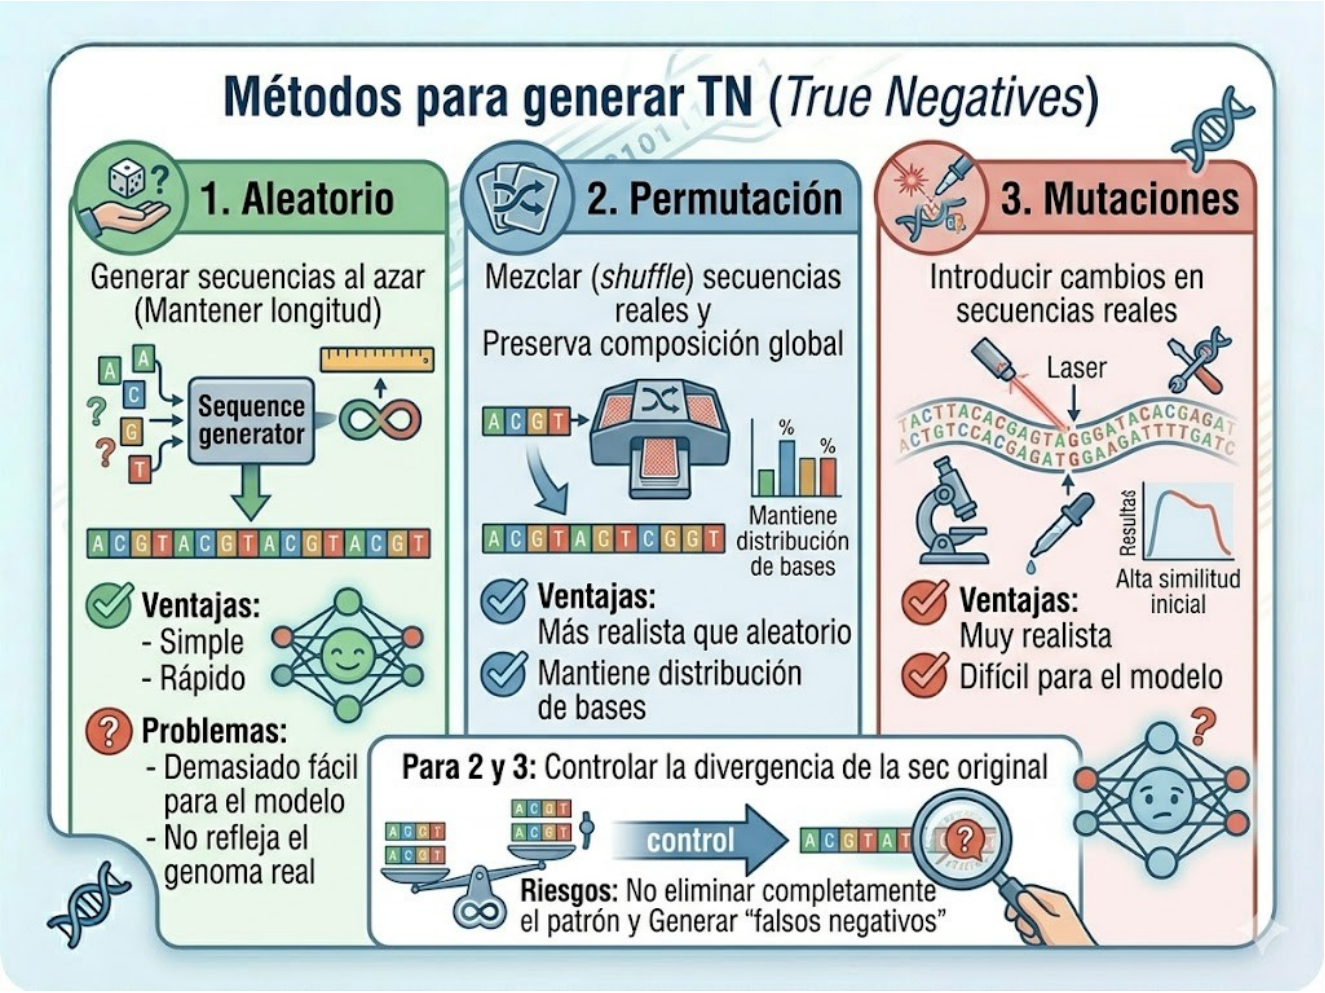

- # Métodos para generar TN:

- 1. Aleatorio:  Generar secuencias al azar (Mantener longitud)
  - Ventajas: Simple, Rápido
  - Problemas: Demasiado fácil para el modelo, No refleja el genoma real
- 2. Permutación: Mezclar (shuffle) secuencias reales y Preserva composición global
  - Ventajas: Más realista que aleatorio, Mantiene distribución de bases
- 3. Mutaciones:  Introducir cambios en secuencias reales
  - Ventajas Muy realista y Difícil para el modelo
- Para 2 y 3 problema es controlar la divergencia de la sec original para alcanzar TN representativos
- Riesgos No eliminar completamente el patrón y Generar “falsos negativos”

# Y ahora al TP

**Trabajo Práctico 4 Pytorch y primeras redes bioinformáticas**

**Objetivo**: En este trabajo pràctico aprenderemos a utilizar pytorch una biblioteca de *machine learning* de código abierto desarrollada por **Meta (antes Facebook)** que se utiliza principalmente para la creación y entrenamiento de redes neuronales, particularmente en ámbitos de investigación. Además comenzaremos con nuestros primeros problemas de redes en Bioinformática.

=> Instalar y ver que anda pytorch (familiarizarse un poco....)

# Secuencias de ADN “one-hot” encoded.

Para poder trabajar con pythorch vamos a primero utilizar un conjunto de datos “MUY SIMPLE”, el mismo consiste en secuencias de ADN de 10 bases (con longitud fija) que han sido clasificadas de acuerdo a que posean (y_true=1) o NO posean (y_true=0) una dada caracteristica simple (por ejemplo una “A” en posiciòn 5.

Como las siguientes:

| Seq | y_true |
|---|---|
| AGGCATGGTC | 0 |
| AATACGTTGA | 0 |
| GAGAAATCCC | 1 |
| CGACATTGGT | 0 |
| ACCGGAATGT | 1 |

Escriba un codigo que convierta sus secuencias de ADN a one-hot encoding y luego en un tensor plano (flat) de pytorch. Convierta tambien los y_true en un tensor de dimension (N,1) y que los valores sean flotantes (esto es importante para poder calcular a LF).

Ejercicio 4.1 a) Utilicé pytorch, con los comandos decritos previamente, para armar una pequeña red que pueda clasificar las secuencias cortas de ADN de acuerdo a su presencia (o no) de una “A” en posición 5. Analice como cae la LF con el entrenamiento, y analicé las mètricas de calidad para un sistema de clasificación (curvas ROC etc).
b) ¿Se le ocurre alguna manera de visualiar gráficamente la performance el modelo? (más alla de las cirvas ROC y PR)

# Ejercicio 4.2

a) Utilicé pytorch para construir y evaluar una red neuronal pequeña que prediga la presencia / ausencia de un promotor en una dada secuencia de ADN.

Luego de entrenar la red con el set de entrenamiento + los negativos sintéticos, y evalue su performance con el set de validación.

Para evaluar la misma, compare la capacidad de predicción de la red utilizando las diferentes métricas, entre el set de entrenamiento y validación y con el avance del entrenamiento (también puede probar y comparar varias arquitecturas)

# Ejercicios 4.3 y 4.4

Ejercicio 4.3 Implemente los 3 métodos descritos previamente para generar los TN (Azar, Permutaciones y mutaciones)

Ejercicio 4.4 Seleccione uno de los modos de construir los TN para tarbajar. Con el mismo, analicé el efecto en la performance predictiva de la red en funciòn de la cantidad de datos de entrenamiento (n) para 3 escenarios i) set balanceado nTP = nTN i) desbalanceado en favor de los positivos  nTP >> nTN (pruebe rangos 1:5-1:100) y iii) desbalanceado en favor de los TN.

# Interpretabilidad del Modelo

¿Cómo puedo saber qué patrones de secuencia aprendió el modelo?

Ejercicio 4.6. a) Utilizando ideas similares a la mencionada, realice “un par” de análisis que permitan comprender qué regiones / motivos de las secuencias de ADN está utilizando su red para predecir la presencia/ausencia de un promotor.

¿Se anima a diseñar una estrategia para generar un “simil” DNA-logo?