Embeddings

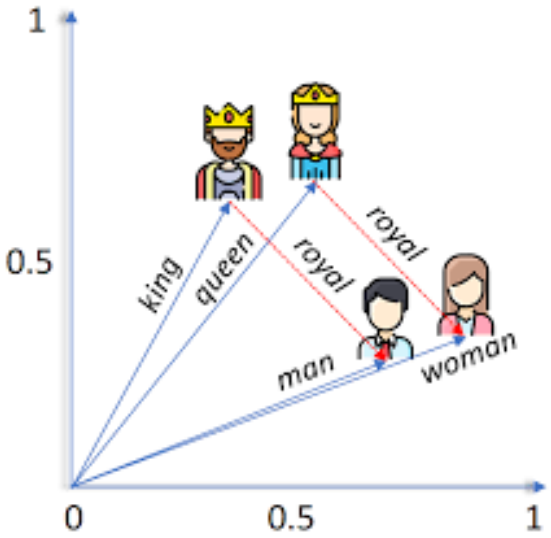
1
0.5
0
0.5
1
king
queen
royal
royal
man
woman

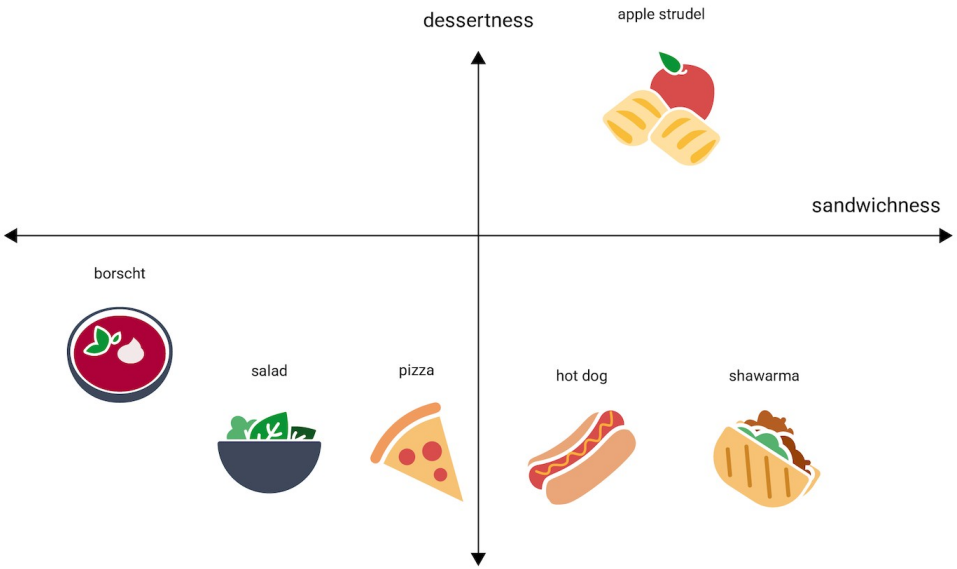
dessertness
apple strudel
sandwichness
borscht
salad
pizza
hot dog
shawarma

Motivación

Datos biológicos y del lenguaje no son numéricos en forma natural:
palabras / ontologías
nucleótidos / secuencias de ADN
aminoácidos / proteínas
átomos y moléculas / quimica

Para usarlos en un modelo, primero hay que convertirlos en números.
ya vimos antes. One-Hot Encoding (una forma un vector binario x cada tipo de dato)
Tiene limitaciones:

genera representaciones dispersas (sparse)
no refleja similitud entre elementos => todos igual de “lejos” entre sí

Necesitamos una representación: más compacta, más informativa y capaz de capturar relaciones entre los objetos

En vez de representar cada elemento como una etiqueta aislada, queremos ubicarlo en un espacio donde la posición tenga significado.

Embeddings

Es una representación “densa” (un vector chico) que datos de mayor (u otra) dimensionalidad.

Se pueden crear usando técnicas clásicas de reducción de dimensionalidad

En DNN los embeddings “aparecen” debido al entrenamiento y el flujo de los tensores por la red

Los ejemplos más utilizados son en palabras:

Veamoslos!

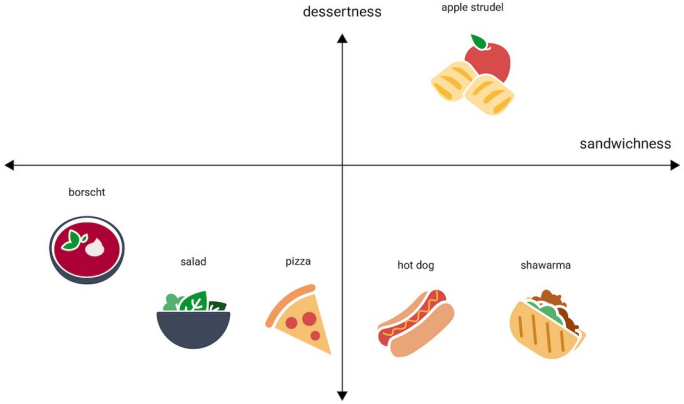

Vamos a un ejemplo con “palabras” - “conceptos”

Suppose that you work as an animal wrangler on a movie with a tempestuous director.

Today you’re filming a sequence where the human heroes are chased by some animals.

The director asks you for a list of animals you can provide in sufficient numbers to produce a scary chase.

Arrange those animals into a chart, where the horizontal axis represents each adult animal’s average top speed and the vertical axis represents its average weight.

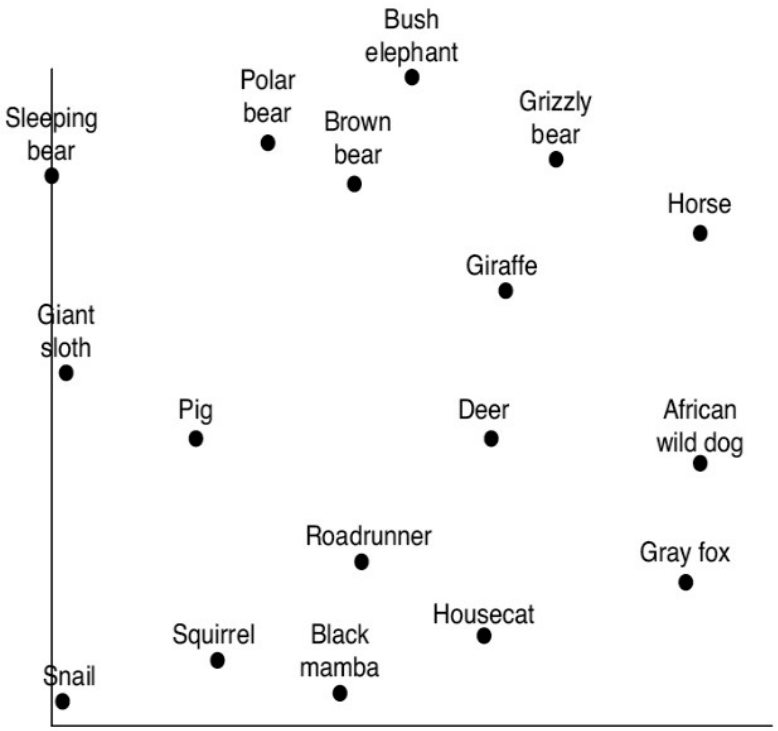

Vamos a un ejemplo con “palabras” - “conceptos”

The director doesn’t even look at the chart. “Horses,” she says, “I want horses. They’re exactly what I want and will be perfect and nothing else will do.” So you bring in the horses, and they rehearse the scene.

Unfortunately, the director is unhappy. “No, no, no!” she says. “The horses are too twitchy and quick. They’re like foxes. Give me horses that are less fox-like.”

How on Earth can you satisfy this request? What does it even mean? Happily, you can do just as she asks with the chart, just by combining arrows.

Vamos a un ejemplo con “palabras” - “conceptos”

“The horses are too twitchy and quick. They’re like foxes. Give me horses that are less fox-like.”

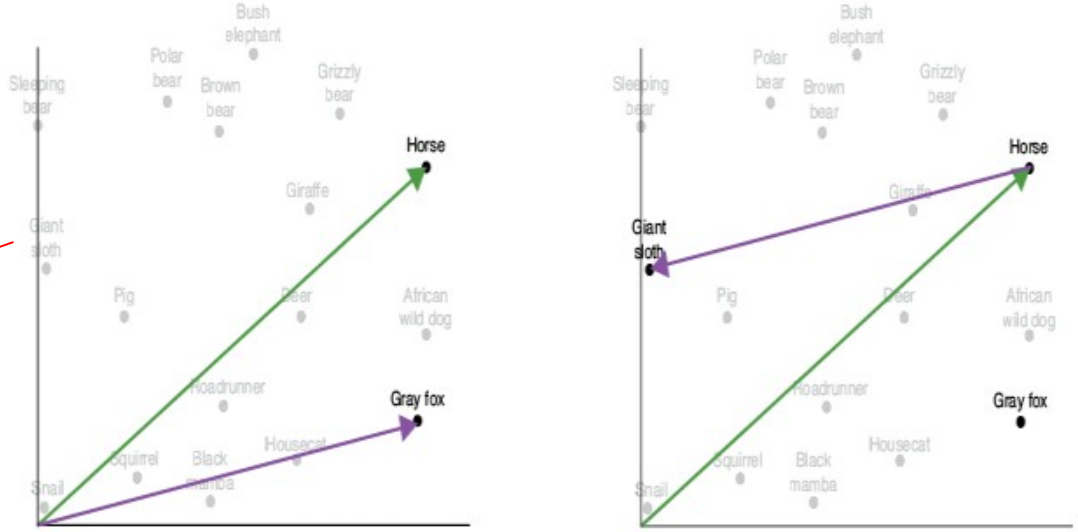

Figure 20-3: Left: Arrows from the bottom left to the horse and fox. Right: Subtracting fox from horse gives us a giant sloth.

Vamos a un ejemplo con “palabras” - “conceptos”

The director throws her latte on the ground. “No no no! Sure,

sloths would look great, but they hardly move! Make them fast! Give me sloths that are like roadrunners!” ¿qué hago?

Vamos a un ejemplo con “palabras” - “conceptos”

The director throws her latte on the ground. “No no no! Sure,

sloths would look great, but they hardly move! Make them fast! Give me sloths that are like roadrunners!” ¿qué hago?

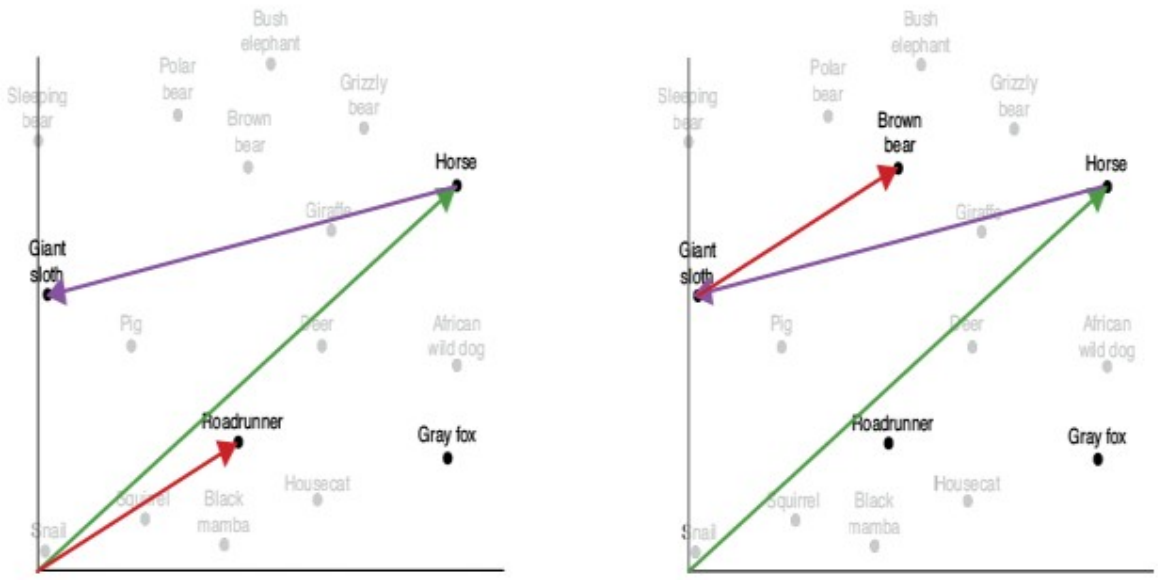

Figure 20-4: Left: We can draw an arrow to the roadrunner. Right: Giant sloth + roadrunner = brown bear.

Vamos a un ejemplo con “palabras” - “conceptos”

The director rolls her eyes dramatically. “Finally. Something that’s fast like horses, but not twitchy like foxes, and quick like roadrunners. It’s only what I asked for in the first place.”

¿Y en biología? Embeddings de aas...

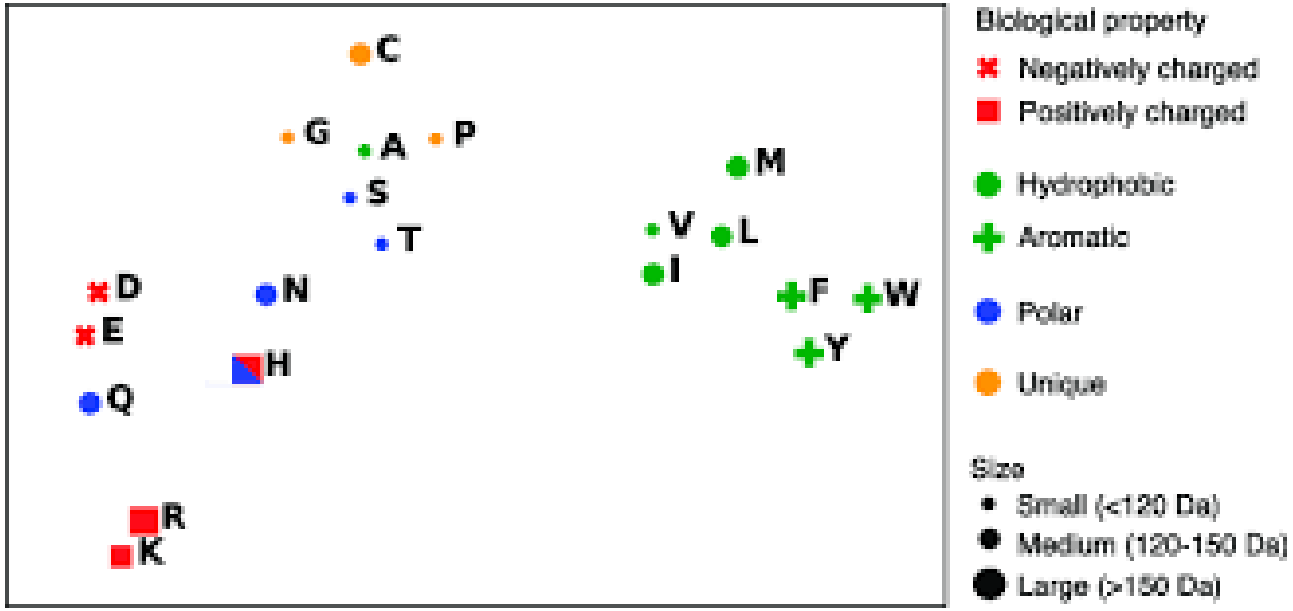

Operaciones de embeddings

Una vez que los objetos están representados como vectores, podemos operar con ellos usando álgebra vectorial. suma y resta, interpolación (promedios, combinaciones) y distancias (similitud)

=> las relaciones entre objetos también se vuelven operaciones geométricas

Analogías vectoriales Las relaciones semánticas se codifican como direcciones en el espacio:
Rey − Hombre + Mujer ≈ Reina
París − Francia + Italia ≈ Roma

Los embeddings organizan los datos en un espacio donde:
conceptos similares → puntos cercanos,
relaciones → vectores consistentes

El embedding no solo representa objetos, sino que:
codifica relaciones como transformaciones lineales en el espacio

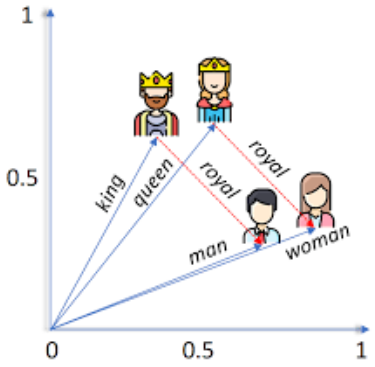

Existen 2 maneras “básicas” de generar embeddings

1) Utilizar PCA (oSVD) y entonces reducir la dimensionalidad y capturar la varianza de las “features”.
2) Entrenar una DNN (i.e una CNN) y utilizar alguna de las dimensiones ocultas y/o transformaciones de la misma como embedding.
   a) En estos casos el embedding dependerá de: a) la arquitectura, b) el modelo de entrenamiento y c) el método de extracción del embedding

Los embedding reemplazan al OHE como “input” de las DNN y son transferibles entre diferentes modelos y objetivos. Además las n-dim del mismo permite “capturar” n relaciones entre los objetos embebidos

Embedding x PCA

aa	Hidropatía	Tamaño	Carga	#Puentes H
A	0	1	0	0
I	2	2	0	0
K	-4	3	1	3
D	-3	2	-1	4

Embedding a partir de Blossum?

	C	S	T	A	G	P	D	E	Q	N	H	R	K	M	I	L	V	W	Y	F	
C	9																				C
S	-1	4																			S
T	-1	1	5																		T
A	0	1	0	4																	A
G	-3	0	-2	0	6																G
P	-3	-1	-1	-1	-2	7															P
D	-3	0	-1	-2	-1	-1	6														D
E	-4	0	-1	-1	-2	-1	2	5													E
Q	-3	0	-1	-1	-2	-1	0	2	5												Q
N	-3	1	0	-2	0	-2	1	0	0	6											N
H	-3	-1	-2	-2	-2	-2	-1	0	0	1	8										H
R	-3	-1	-1	-1	-2	-2	-2	0	1	0	0	5									R
K	-3	0	-1	-1	-2	-1	-1	1	1	0	-1	2	5								K
M	-1	-1	-1	-1	-3	-2	-3	-2	0	-2	-2	-1	-1	5							M
I	-1	-2	-1	-1	-4	-3	-3	-3	-3	-3	-3	-3	-3	1	4						I
L	-1	-2	-1	-1	-4	-3	-4	-3	-2	-3	-3	-2	-2	2	2	4					L
V	-1	-2	0	0	-3	-2	-3	-2	-2	-3	-3	-3	-2	1	3	1	4				V
W	-2	-3	-2	-3	-2	-4	-4	-3	-2	-4	-2	-3	-3	-1	-3	-2	-3	11			W
Y	-2	-2	-2	-2	-3	-3	-3	-2	-1	-2	2	-2	-2	-1	-1	-1	-1	2	7		Y
F	-2	-2	-2	-2	-3	-4	-3	-3	-3	-3	-1	-3	-3	0	0	0	-1	1	3	6	F
	C	S	T	A	G	P	D	E	Q	N	H	R	K	M	I	L	V	W	Y	F	

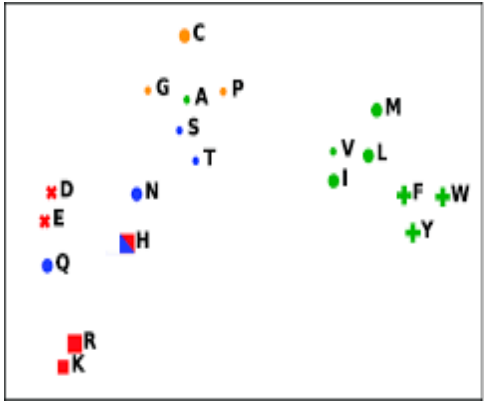

6. Embeddings vs One-Hot Encoding

ONE-HOT ENCODING (OHE)

SPARSE VS **DENSOS**

SIN NOCIÓN DE SIMILITUD

ESTRUCTURA SEMÁNTICA

M_{OHE}

	perro	gato	pelota	mesa	silla	Extra
perro	1	0	0	0	0	0
gato	0	1	0	0	0	0
pelota	0	0	1	0	0	0
mesa	0	0	0	1	0	0
silla	0	0	0	0	1	1

M_{OHE}

perro - ✗ - gato

NO SIMILITUD

NO SIMILITUD VECTOR

DISOCIA CONCEPTOS

EMBEDDINGS

M_E

	Dim 1	Dim 2	...	Dim 4	Dim 5
perro	0.8	-0.2	0.3	-0.2	0.8
gato	0.8	-0.2	-0.2	-0.2	-0.2
pelota	0.8	-0.3	-0.1	-0.2	-0.3
mesa	0.8	-0.2	-0.2	0.1	0.2
silla					

M_E

perro
gato
similarity score
0.8
pelota
mesa
silla

SIMILITUD SEMÁNTICA

RELACIONES CONCEPTUALES

perro gato

ASOCIA CONCEPTOS

“Word” embeddings

Los embeddings de palabras son extremadamente “útiles” ya que usar OHE de palabras es inviable.

Entre los más conocidos están el Word2vec que aprende embeddings basados en el contexto en el que aparecen las palabras.

Hay dos enfoques principales, que varían en cómo se entrena la red:

CBOW (Continuous Bag of Words)

Skip-gram

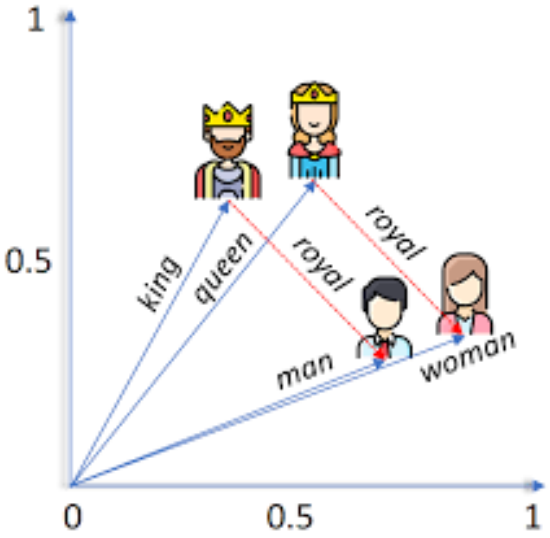

Rey-Hombre+Mujer = ?

CBOW y Skip-gram

CBOW: predice una palabra basándose en su contexto.

Input: "El perro corre en el parque" => output (y-true) “perro”

Aprende a asociar contextos similares con palabras similares.

Cons: No representa bien palabras raras (porque promedia contextos)

Skip-Gram: predice el contexto (vecino) dada la palabra

Input: “corre” => output (y-true) n=2: el, perro, en

Pros: Funciona bien con datos poco frecuentes, Captura mejor relaciones semánticas.

Cons: más lento que CBOW y requiere más datos

Resumen embeddings

Representación densa y estructurada vectores de baja dimensión (vs OHE) el espacio tiene geometría con significado: similitud → proximidad en el espacio

Capturan múltiples relaciones simultáneamente donde cada dimensión contribuye a describir el objetopropiedades locales, contexto, relaciones funcionales

un mismo vector puede reflejar varias “facetas” del objeto

Transferibilidad

lo embeddings aprendidos en una tarea pueden reutilizarse en otra, Reutilizables entre modelos

permiten transfer learning desacoplan representación de tarea

Embedding como “lookup table”: cada token → índice → vector aprendido

el modelo aprende esta tabla durante el entrenamiento

Hoy son base de la mayoría de los modelos modernos (NLP y bio)

RESUMEN DE EMBEDDINGS (DENSOS Y ESTRUCTURADOS)

REPRESENTACIÓN Y ESTRUCTURA

1a. VS ONE-HOT ENCODING (OHE)

OHE

Slaře

1	...			1
	1			
		1		
			1	
1	...			1

VS
vs OHE

Embeddings

0.8	-0.2	-0.2	0.8
-0.2	0.		
0.8	0		
-0.2	-0.2		
0.8	0.2	0.3	-0.2

ESTRUC-TURA

Vectores ruidosos, sparse, baja dimensión

Vectores densos, baja dimensión

1b. ESPACIO GEOMÉTRICO CON SIGNIFICADO

PROXIMIDAD → **SIMILITUD**

perro
gato
DISTANCIA
pelota
raqueta

PROXIMIDAD → **SIMILITUD**

CAPTURA DE MÚLTIPLES RELACIONES

2a. MÚLTIPLES FACETAS SIMULTÁNEAMENTE

Cada dimensión contribuye a describir

MAMÍFERO
DOMÉSTICO
DOMÉSTICO
CONCEF
LEAL
OBJETO
(ej. PERRO)
ARBAHRA
MASCOTA
CORTA VIDA

2b. RELACIONES FUNCIONALES

REPRESENTA **FUNCIÓN**

perro → morder → gato

REPRESENTA **CONTEXTO**

perro → parque → dueño

REPRESENTA **PROPIEDAD LOCAL**

perro → pelaje

TRANSFERIBILIDAD Y TRANSFER LEARNING

3a. REUTILIZABLES ENTRE MODELOS

MODELO A
(APRENDIZAJE ORIGINAL)
1D EMBEDDING APRENDIDO

TRANSFERIBILIDAD →

MODELO B
(NUEVA TAREA)

3b. TRANSFER LEARNING

permiten Transfer Learning — DESACOPLADO

DESACOPLA REPRESENTACIÓN DE TAREA

Reutilizables

INPUT
(TOKEN)

EMBEDDING LAYER
(CONGELADA/FIJA)

TASK LAYERS
(ESPECÍFICAS/NUEVAS)

OUTPUT
TAREA B

EMBEDDING COMO "LOOKUP TABLE"

4a. TOKEN → ÍNDICE → VECTOR APRENDIDO

TAREA DE ENTRENAMIENTO

VECTA DE ENTRENIDO

LOOKUP TABLE

TOKEN	ÍNDICE	VECTOR (APRENDIDO)
token A	índice A	[0.1, 0.5, ...]
token B	índice B	[0.2, 0.4, ...]

DATO ENTRENAMIENTO
(ej. "hola")

índice X → vector X

APRENDER DURANTE ENTRENAMIENTO

ACTUALIZACIÓN

4b. BASE DE MODELOS MODERNOS
(NLP y bio)

NLP
texto, audio

bio
ADN, proteínas

Hoy son base de la mayoría de los modelos modernos

Preguntas a ver si entendimos

¿Por qué el one-hot encoding no es una buena representación para palabras o secuencias en problemas complejos?

Si dos elementos tienen embeddings cercanos en el espacio, ¿qué implica eso sobre su relación?
¿Siempre significa lo mismo en todos los modelos?

¿Cuál es la diferencia conceptual entre un embedding obtenido por PCA y uno aprendido por una red neuronal?

¿Por qué un embedding puede reutilizarse en diferentes tareas? ¿En qué situaciones esto podría fallar?

En términos prácticos, ¿qué significa decir que un embedding es una lookup table?
¿Cómo se relaciona esto con una matriz en una red neuronal?

Si entrenás una CNN sobre secuencias de ADN, ¿en qué sentido se puede decir que la red está aprendiendo embeddings, incluso si no definiste una capa explícita de embedding?

Y ahora el TP 6 Regularización

Objetivo: El objetivo del presente TP es familiarizarse con las denominadas técnicas de regularización (batch normalization, L1, L2, Drop-out) que lo que buscan es evitar el “overfitting”. También analizaremos cómo determinar el overfitting y cómo el mismo se relaciona con la complejidad de la red.

Para hacer este TP utilizaremos los datos y modelo del TP anterior, o sea vamos a analizar y evitar el overfitting en la CNN utilizada para determinar sitios de unión al FT. Recomendamos trabajar con secuencias de no más de 100nt.

¿cómo evidenciar el overfitting?

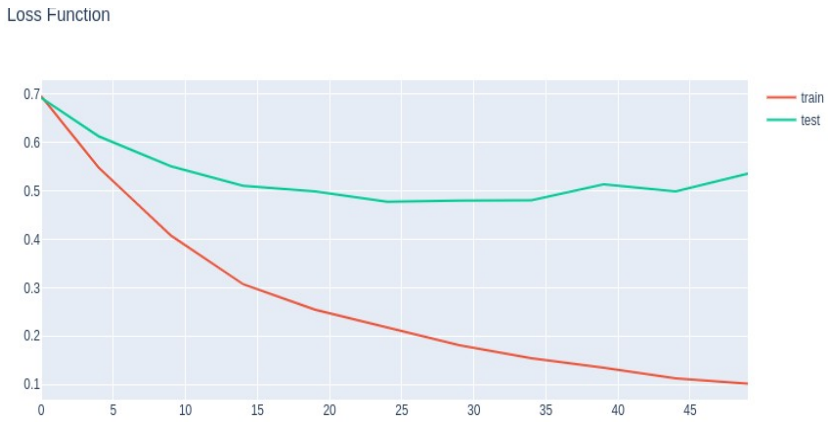

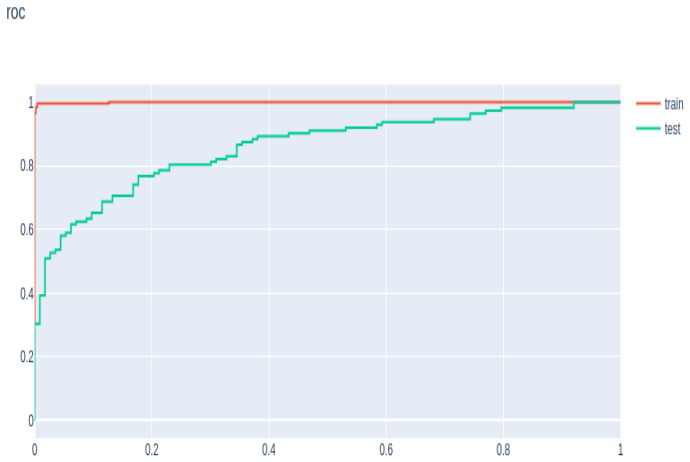

Ejercicio 6.1 Utilizando los datos y el tipo de CNN vistos en el TP anterior cosntruya una red y analicé la performance de las diferentes métricas (LF, Accuracy, ROC-AUC, CF, PR-AUC etc.) para determinar el overfitting. Luego Analicé el efecto de la cantidad de kernels (utilice valores en en el rango 2-24) y su dimensión (3 a 20nt). Si puede muestre los resultados en una tabla/gráfico. ¿qué puede decir del overfitting en relación con la complejidad de la red?

¿cuál es la mejor red que puede obtener para discriminar el set entrenamiento? ¿Que pasa si ahora además busca minimizar el overfittng?

Ejercicio 6.2 y 6.3

Ejercicio 6.2. Seleccione del ejercicio anterior 1 (o 2) arquitecturas donde haya observado un overfitting. Incluya primero batch normalization y luego dropout (juegue un poco con el hiperparámetro “p”).

Analice el efecto de estas modificaciones en: a) la velocidad del aprendizaje, b) el overfitting y c) la capacidad final del modelo. ¿Es capaz ahora de obtener un mejor modelo que antes?

Ejercicio 6.3 (opcional). Incluya en los alguno(s) de los modelos anteriores L2 Regularización Analice el efecto de estas modificaciones en: a) la velocidad del aprendizaje, b) el overfitting y c) la capacidad final del modelo. Nota: pruebe en que casos L2 tiene más efecto (con o sin dropout), ¿por qué?

6.4

Ejercicio 6.4 Construya un set desbalanceado donde la relación positivas / negativas sea 1 entre 1/10 - 1/100 (o más) y analicé el efecto en la performance del modelo al utilizar la LF propuesta y variar el hiperparámetro pos_weight.

¿qué puede decir de la capacidad del modelo para detectar nuevos sitios de unión del FT?

Caso final: 6.5

Para finalizar nuestras redes para ADN combinaremos todo lo aprendido en un escenario màs realista. Para ello tenga en cuenta que usted cuenta con el BED con la información de los picos del ChipSeq de todos los cromosomas, y que puede obtener las secuencias de los otros cromosomas en https://hgdownload.soe.ucsc.edu/goldenPath/hg38/chromosomes/

Ejercicio 6.5 Utilizando las secuencias positivas de uno (o màs) cromosomas (excluyendo el 22) construya y entrene (utilizando lo aprendido en los TPs 5 y 6) un modelo que sea capaz de escanear el Chr22 (o una sección el mismo) y determinar los picos de unión e JunD al mismo.

Construya un gráfico de “Señal” vs Chrom:pos y superponerlo con el gràfico equivalente obtenido del BED file.

¿cuántas de las 561 regiones es capaz de reconocer con umbral de no más de 5-10% de FP (verificados)?

¿Detecta alguna región no cubierta en el BED?

¿Que puede decir de la calidad del modelo final?

Vam

The director